



rapport complet:

Analyse des candidats au baccalauréat en Tunisie

Réalisé par :

Souhayel Kamel

Arij Turki

Encadré par :

Mme Maroua Labidi

Année universitaire : 2025 – 2026

sommaire:

1. Contexte métier

2. Objectifs de l'étude de cas

3. Analyse du Jeu de Données et Identification des KPI

3.0 Source des Données

3.1 Structure des Données

3.2 Qualité des données

3.3 KPIs Retenus

4. Visualisations et Interprétations

4.0 Vue Globale du Dashboard — KPIs Principaux

4.1 Filières les Plus Choies & Répartition par Genre

4.2 Taux de Réussite par Genre & par Section

4.3 Performance par Région (CRE)

5. Bilan et Synthèse

6. Références Scientifiques

RAPPORT D'ANALYSE CANDIDATS AU BACCALAURÉAT EN TUNISIE

1. Contexte métier

Le secteur de l'éducation en Tunisie joue un rôle essentiel dans la formation des ressources humaines. L'analyse des données des candidats au baccalauréat permet aux décideurs (ministère, établissements, chercheurs) de :

- Comprendre les tendances d'orientation des élèves
- Identifier les déséquilibres (genre, région, section)
- Optimiser la planification éducative

Ce type d'étude s'inscrit dans une logique de data-driven decision making (prise de décision basée sur les données).

nous passons d'une gestion administrative à une gestion analytique. L'utilisation d'outils modernes (Python, Streamlit) permet de transformer des milliers de lignes de fichiers CSV bruts en informations exploitables (Insights). Cela permet de détecter, par exemple, si une baisse de performance dans une région est due à un manque d'effectifs ou à une problématique locale spécifique.

2. Objectifs de l'Etude de Cas

L'étude vise à :

- Analyser la répartition des candidats selon les sections
- Étudier l'impact du genre sur le choix des spécialités
- Comparer les types de candidature (public, privé, libre)
- Identifier les régions avec les effectifs les plus élevés
- Extraire des indicateurs clés pour mieux comprendre le système éducatif

3. Analyse du Jeu de Données et Identification des KPI

3.0 Source des Données

Les données exploitées proviennent du portail tunisien de données ouvertes (data.gov.tn). Deux fichiers officiels ont été utilisés :

- `datasetbac.csv` — Candidats inscrits au Baccalauréat 2024, désagrégés par région (CRE), section, type de candidature et genre
- `admis-bac-2024.csv` — Résultats des admis au Baccalauréat 2024, avec la même structure

Ces données sont de nature administrative et statistique, produites par le Ministère de l'Éducation tunisien. Leur

caractère officiel garantit leur fiabilité pour une analyse à l'échelle nationale.

on était retrouvé avec deux fichiers séparés: un pour les inscrits et un pour les admis. Le problème c'est que tout seul, chaque fichier ne nous apporte rien. Avec seulement les inscrits on ne sais pas qui a réussi, et avec seulement les admis on ne sais pas combien s'étaient présentés au départ. Donc pour pouvoir calculer un taux de réussite, on avait besoin de les relier.

Pour faire ça on a utilisé **pd.merge()** avec une jointure gauche sur trois clés en même temps : **la région, la filière et le genre**. on a choisi ces trois clés parce que ça nous donne une précision maximale

Code Streamlit correspondant :

```
# Fusion pour le calcul de performance
df_perf = pd.merge(
    df_inscrits.groupby(['CRE', 'SECTION', 'GENRE'])['EFFECTIF'].sum().reset_index(),
    df_admis.groupby(['CRE', 'SECTION', 'GENRE'])['EFFECTIF'].sum().reset_index().rename(columns={'EFFECTIF': 'ADMIS'}),
    on=['CRE', 'SECTION', 'GENRE'],
    how='left'
).fillna(0)

df_perf['TAUX'] = (df_perf['ADMIS'] / df_perf['EFFECTIF'] * 100).fillna(0)
return df_inscrits, df_perf
except Exception as e:
    st.error(f"Erreur de chargement : {e}")
    return None, None

if_inscrits, df_perf = load_and_merge_data()
```

3.1 Structure des Données

Colonne	Type	Description	Valeur
CRE	Texte	Commissariat	26 régions

		Régional d'Éducation	
SECTION	Texte	Filière du baccalauréat	7 filières
CANDIDATUR E	Texte	Type d'établisseme nt	Public / Privé
GENRE	Texte	Genre du candidat	F / M
EFFECTIF	Numérique	Nombre de candidats	Entier ≥ 0

3.2 Qualité des Données

- Aucun doublon après vérification automatisée
- Cohérence parfaite des nomenclatures de sections entre les deux fichiers

Nettoyage appliqué :

- uniformisé les noms de colonnes
- corrigé les valeurs numériques
- standardisé les données texte

Code Streamlit correspondant :

```
# Nettoyage et standardisation
for data in [df_inscrits, df_admis]:
    data.columns = data.columns.str.strip().str.upper()
    data['EFFECTIF'] = pd.to_numeric(data['EFFECTIF'], errors='coerce').fillna(0)
    for col in ['CRE', 'SECTION', 'GENRE']:
        if col in data.columns:
            data[col] = data[col].astype(str).str.strip().str.upper()
```

3.3 KPIs Retenus

KPI	Formule	Valeur 2024
Taux de Réussite Global	Admis / Inscrits × 100	53,05 %
Total Inscrits	Somme des effectifs inscrits	140 211
Total Admis	Somme des effectifs admis	74 379
Taux par Section	Admis section / Inscrits section	41,7 % → 86,5 %
Taux par Région	Admis région / Inscrits région	36,7 % → 68,9 %
Taux par Genre	Admis genre / Inscrits genre	F: 70,3% M: 37,4%

4. Visualisations et Interprétations

4.0 Vue Globale du Dashboard — KPIs Principaux




Figure 1 — Vue globale du Dashboard Bac 2024 : KPIs nationaux et sidebar de filtrage

- Le dashboard affiche trois KPIs agrégés au niveau national. Avec 140 211 candidats inscrits et 74 379 admis, le taux de réussite global s'établit à 53,05 %. Cela signifie qu'un candidat sur deux réussit son baccalauréat. La sidebar propose un filtre par région (CRE) qui recalcule dynamiquement l'ensemble des indicateurs et visualisations, permettant une analyse contextualisée pour chaque décideur régional.

- Pour rendre l'analyse encore plus utile, on a ajouté une **barre de filtres** dans la sidebar de notre application Streamlit. L'idée c'est simple : au lieu d'avoir des graphiques figés qui montrent uniquement les données nationales, on voulait que n'importe qui puisse sélectionner une région spécifique et voir ses propres résultats en temps réel.

Code Streamlit correspondant :

```

40 if df_inscrits is not None:
41     # --- FILTRES SIDEBAR ---
42     st.sidebar.header("🔍 Options de filtrage")
43     region = st.sidebar.selectbox("Choisir une région (CRE) :", ["TOUTES"] + sorted(df_inscrits["CRE"].unique().tolist()))
44
45     # Application des filtres
46     df_ins_filtered = df_inscrits.copy()
47     df_perf_filtered = df_perf.copy()
48
49     if region != "TOUTES":
50         df_ins_filtered = df_ins_filtered[df_ins_filtered["CRE"] == region]
51         df_perf_filtered = df_perf_filtered[df_perf_filtered["CRE"] == region]

```


```

53     # --- TITRE ET KPI ---
54     st.title("📊 Dashboard de Performance Bac 2024")
55
56     col_k1, col_k2, col_k3 = st.columns(3)
57     total_ins = int(df_ins_filtered['EFFECTIF'].sum())
58     total_adm = int(df_perf_filtered['ADMIS'].sum())
59
60     col_k1.metric("Total Candidats", f"{total_ins:,}")
61     col_k2.metric("Total Admis", f"{total_adm:,}")
62     taux_global = (total_adm / total_ins * 100) if total_ins > 0 else 0
63     col_k3.metric("Taux de Réussite Global", f"{taux_global:.2f} %")
64
65     st.markdown("---")

```

4.1 Filières les Plus Choisies & Répartition par Genre

1. Filières les plus choisies



2. Répartition des Inscrits par Genre




Figure 2 — Visualisation 1 (histogramme filières) & Visualisation 2 (donut chart genre)

Interprétation — Visualisation 1 : Filières les plus choisies

L'histogramme révèle une concentration très marquée sur la filière Économie & Gestion, qui domine largement avec environ 46k inscrits ($\approx 33\%$ du total national). Elle est suivie par Sciences Expérimentales ($\sim 28k$) et Lettres ($\sim 27k$). À l'opposé, les filières Mathématiques ($\sim 8k$) et Sport ($\sim 1,4k$) sont les moins choisies. Cette distribution en queue de

distribution suggère que les candidats privilégient les filières perçues comme plus accessibles ou offrant plus de débouchés professionnels, au détriment des filières scientifiques d'excellence à forte sélectivité.

Interprétation — Visualisation 2 : Répartition par Genre

Le donut chart affiche une quasi-parité d'inscription : 52,4 % de garçons (M) contre 47,6 % de filles (F). Bien que les garçons soient légèrement plus nombreux à s'inscrire, cet écart de moins de 5 points traduit une féminisation avancée de l'accès au baccalauréat. Cette quasi-parité d'inscription, croisée avec les taux de réussite (analysés en section 4.2), révèle un paradoxe frappant : **les filles, minoritaires en nombre, sont majoritaires en succès.**


Code Streamlit correspondant :

```
67 # --- LIGNE 1 : VOLUMES ---
68 col1, col2 = st.columns(2)
69 with col1:
70     st.subheader("📊 1. Filières les plus choisies")
71     fig1 = px.bar(df_ins_filtered.groupby("SECTION")["EFFECTIF"].sum().reset_index().sort_values("EFFECTIF", ascending=False),
72                  x="SECTION", y="EFFECTIF", color="SECTION", text_auto='.2s')
73     st.plotly_chart(fig1, use_container_width=True)
74 with col2:
75     st.subheader("📊 2. Répartition des Inscrits par Genre")
76     fig2 = px.pie(df_ins_filtered.groupby("GENRE")["EFFECTIF"].sum().reset_index(), values="EFFECTIF", names="GENRE", hole=0.4,
77                  color_discrete_sequence=["#e74c3c", "#3498db"]) # Rouge pour F, Bleu pour M
78     st.plotly_chart(fig2, use_container_width=True)
79
80 st.markdown("---")
```

4.2 Taux de Réussite par Genre & par Section



3. Taux de Réussite par Genre



4. Taux de Réussite par Section




Figure 3 — Visualisation 3 (taux par genre) & Visualisation 4 (taux par section, gradient RdYlGn)

Interprétation — Visualisation 3 : Taux de Réussite par Genre

Le graphique est sans appel : les filles (F) atteignent un taux de réussite de 70,3 %, contre seulement 37,4 % pour les garçons (M)

soit un écart colossal de 32,9 points de pourcentage. Cet écart, **l'un des plus larges observés dans les examens nationaux de la région**, inverse totalement la logique du

nombre : bien que moins nombreuses à s'inscrire, les filles représentent 63 % des admis. Ce phénomène peut s'expliquer par une meilleure régularité dans le travail scolaire, un moindre taux d'absentéisme et des facteurs socioculturels qui exposent davantage les garçons au décrochage (emploi informel, pression familiale).

Interprétation — Visualisation 4 : Taux de Réussite par Section

Le gradient de couleur RdYlGn (rouge → jaune → vert) permet une lecture immédiate des performances : Sport affiche le meilleur taux (86,5 %, barre verte intense), suivi de Mathématiques (81,7 %). À l'autre extrême, Lettres obtient le taux le plus faible (41,7 %, barre rouge). Un paradoxe structurel se confirme : les filières les moins peuplées (Sport : 1,4k inscrits, Mathématiques : 8k) surperforment massivement les filières les plus choisies (Économie & Gestion : 46k, Lettres : 27k). Ce phénomène s'explique par un effet de sélection : les filières d'excellence attirent des profils plus rigoureux et mieux préparés, tandis que les filières massifiées concentrent une hétérogénéité de niveaux plus grande.

Code Streamlit correspondant :

```
82 # --- LIGNE 2 : PERFORMANCE PAR GENRE ET SECTION ---
83 col3, col4 = st.columns(2)
84 with col3:
85     st.subheader("📊 3. Taux de Réussite par Genre")
86     df_genre_perf = df_perf_filtered.groupby("GENRE").agg({"EFFECTIF": "sum", "ADMIS": "sum"}).reset_index()
87     df_genre_perf["TAUX"] = (df_genre_perf["ADMIS"] / df_genre_perf["EFFECTIF"] * 100)
88     fig3 = px.bar(df_genre_perf, x="GENRE", y="TAUX", color="GENRE", text_auto=".1f",
89                 color_discrete_map={"F": "#e74c3c", "M": "#3498db"},
90                 labels={'TAUX': 'Taux de Réussite (%)'})
91     st.plotly_chart(fig3, use_container_width=True)
92
93 with col4:
94     st.subheader("📊 4. Taux de Réussite par Section")
95     df_sec = df_perf_filtered.groupby("SECTION").agg({"EFFECTIF": "sum", "ADMIS": "sum"}).reset_index()
96     df_sec["TAUX"] = (df_sec["ADMIS"] / df_sec["EFFECTIF"] * 100)
97     fig4 = px.bar(df_sec, x="SECTION", y="TAUX", color="TAUX", color_continuous_scale="RdYlGn", text_auto=".1f")
98     st.plotly_chart(fig4, use_container_width=True)
99
100 st.markdown("---")
```

4.3 Performance par Région (CRE)

📍 5. Performance par Région (CRE)




Figure 4 — Visualisation 5 : Taux de réussite par région (CRE), palette Viridis, tri décroissant

Interprétation — Visualisation 5 : Performance par Région

La visualisation révèle une fracture territoriale nette et préoccupante. Sfax 2 domine le classement national avec un taux de 68,9 %, suivie de Mahdia (64,7 %), Sfax 1 (62,6 %), Monastir (61,3 %) et Sousse (60,6%). Ces cinq régions performantes forment un arc géographique côtier du Centre-Est tunisien, historiquement plus développé économiquement. À l'opposé, les régions de l'intérieur et du Sud-Ouest ferment le classement : Kasserine (42,8 %), Jendouba (40,4 %) et surtout Gafsa en dernière position avec seulement 36,7 %. L'écart entre le premier et le dernier atteint 32,2 points, signalant une inégalité structurelle profonde dans la qualité et la densité de l'encadrement éducatif selon les territoires

Code Streamlit correspondant :

```
102 # --- LIGNE 3 : PERFORMANCE PAR RÉGION ---
103 st.subheader("📊 5. Performance par Région (CRE)")
104 df_reg = df_perf_filtered.groupby("CRE").agg({"EFFECTIF": "sum", "ADMIS": "sum"}).reset_index()
105 df_reg["TAUX"] = (df_reg["ADMIS"] / df_reg["EFFECTIF"]) * 100
106 fig5 = px.bar(df_reg.sort_values("TAUX", ascending=False), x="CRE", y="TAUX", color="TAUX", color_continuous_scale="Viridis", text_auto=".1f")
107 st.plotly_chart(fig5, use_container_width=True)
108
```

5. Bilan et Synthèse

- Performance nationale modérée à 53,05 % : un candidat sur deux échoue, signal d'alerte sur l'efficacité pédagogique globale
- Paradoxe volume/réussite : les filières les plus peuplées (Économie & Gestion, Lettres) sous-performent, tandis que les filières d'excellence (Sport 86,5 %, Mathématiques 81,7 %) surperforment avec des effectifs réduits
- Avantage féminin massif : +32,9 pts d'écart (Filles 70,3 % vs Garçons 37,4 %), les filles représentent 63 % des admis malgré une inscription minoritaire
- Fracture territoriale Nord-côte / intérieur-Sud : 32 pts d'écart entre Sfax 2 (68,9 %) et Gafsa (36,7 %), reflétant des inégalités structurelles de ressources éducatives

5. Références Scientifiques

Sources des Données

- Ministère de l'Éducation Tunisien (2024). Données Baccalauréat 2024. Portail Open Data Tunisie.

<https://data.gov.tn>

Bibliographie Technique

- McKinney, W. (2022). Python for Data Analysis. O'Reilly Media.
- Streamlit Inc. (2024). Streamlit Documentation.
<https://docs.streamlit.io>
- Plotly Technologies Inc. (2024). Plotly Python Graphing Library. <https://plotly.com/python/>